


פרויקט גמר: בקרת תנועה מבוססת בינה מלאכותית



שמות התלמידים:	תעודות זהות
יפתח שלו	215631045
אלון אוחנה	216721084

בהנחיית:

אורן למדן

אייל רוזנבלט

יאיר קלינשטרן

תוכן עניינים

2	תוכן עניינים
3	הקדמה
4	1. מבוא ורקע כללי
4	1.1 תיאור המצב הקיים בתחום
7	1.1.1 היבט חברתי
8	1.1.2 היבט מדעי
11	1.1.3 היבט טכנולוגי
13	1.2 הבעיות העיקריות במצב הקיים
17	1.3 פתרונות קיימים בתחום
18	2. תהליך המחקר והפיתוח
18	2.1 ניתוח מרחב הבעייה ומרחב הפתרונות
20	2.2 טבלת השוואה בין אפשרויות הפתרון
22	3. מימוש הפתרון
22	3.1 מבנה המערכת שנבחרה
31	3.2 תרשימי זרימה של התוכנה
32	3.3 תיאור מפורט של מרכיבי החומרה במערכת
35	3.4 בחינה והערכה של ביצועי המערכת
38	4. סיכום
41	5. ביבליוגרפיה

הקדמה

בפרוייקט שלנו אנו מציגים מערכת אשר מטרתה היא צמצום זמני ההמתנה של כלי הרכב בצומת. המערכת שלנו כוללת מצלמה המוצבת בצומת תנועה לצורך ניטור בזמן אמת של מצב התנועה. המצלמה מקליטה את התנועה ושולחת את הנתונים למחשב RPI, המשתמש בלמידת חיזוקים (Reinforcement Learning) כדי לקבוע את הצבע האופטימלי של רמזורי התנועה בצומת. בשיטה זו נוכל למקסם את זרימת התנועה ולשפר את יעילות הצומת על ידי התאמה דינמית של זמני הרמזורים בהתאם למצב התנועה בזמן אמת.

למידת חיזוקים מאפשרת ל-RPI ללמוד לאורך זמן את הפעולות האופטימליות (צבעי הרמזורים) על בסיס משוב (תגמול) שהוא מקבל מהביצועים של המערכת. באמצעות ניתוח נתונים כגון זמני המתנה ודפוסי תנועה, ה-RPI משפר באופן מתמיד את קבלת ההחלטות שלו, מפחית עומסי תנועה ומשפר את היעילות הכוללת של הצומת

1. מבוא ורקע כללי

1.1 תיאור המצב הקיים בתחום

התחבורה הממונעת – בין אם מדובר ברכב פרטי, אוטובוס, רכבת או אמצעי תחבורה אחר – מהווה נדבך מרכזי בהתנהלות היומיומית של הפרט ובתפקוד התקין של מערכות חברתיות, כלכליות וממשלתיות. אחד היתרונות הבולטים של תחבורה זו הוא יכולתה להעביר קבוצות גדולות של אנשים למרחקים ארוכים בזמן קצר ובאופן נוח, יעיל ובטוח. כאשר מתקיימים התנאים האופטימליים – כלומר, תנועה רציפה, תזמון מדויק ורמת בטיחות גבוהה – התרומה לפרודוקטיביות של הפרטים ולמערכת הכלכלית כולה היא משמעותית.

כדי לאפשר זרימה חופשית ויעילה של כלי רכב, יש לבנות תשתית תחבורתית חכמה – מערכת כבישים היררכית המחברת בין נקודות קצה לבין עורקי תחבורה מרכזיים. הכבישים הקטנים מובילים את הרכב אל הכבישים המהירים יותר, שם מתבצעת עיקר הנסיעה, ובהמשך הרכב שב לכבישים קטנים המובילים אותו ליעדו. מודל זה יוצר רשת תחבורה מסועפת, אך סדורה, אשר מאפשרת כיסוי תחבורתי רחב תוך חסכון בשטח ובמשאבים.

אחד האתגרים המרכזיים ברשת זו הוא ניהול מפגשים בין כבישים – הצמתים. אף כי הפתרון היעיל ביותר ברמה התנועתית הוא הפרדה מפלסית באמצעות גשרים או מנהרות, פתרונות אלה כרוכים בעלויות גבוהות, זמן ביצוע ממושך והתאמות תשתית מורכבות. מסיבה זו, הצומת המישורית נותרה הפתרון הנפוץ והמעשי ביותר. צומת מאפשרת לכלי רכב מכיוונים שונים לחלוף זה לצד זה בבטחה, לבצע פניות ולשנות מסלולים – כל זאת תוך ויסות קפדני של זרימת התנועה.

עם זאת, צמתים עלולים להפוך לנקודות חיכוך תחבורתיות, במיוחד בשעות עומס, ולהוביל לעיכובים ואף לסיכון בטיחותי. ניהול לקוי של צומת או שגיאות אנוש עלולים לגרום לתאונות קשות, ולכן נדרשת מערכת בקרה מהימנה שתשמור על סדר תנועתי ובטיחותי. אחת הדרכים היעילות להתמודד עם אתגר זה היא באמצעות התקנת רמזורים.

הרמזורים ממלאים תפקיד כפול: מצד אחד, הם שומרים על בטיחות המשתמשים – הולכי רגל ונהגים כאחד – על ידי הקצאת זכות קדימה והפחתת סיכון להתנגשות; מצד שני, הם מאפשרים תזמון מדויק יותר של תנועת כלי רכב, תורמים לצמצום עומסים ומייעלים את התפקוד הכולל של הצומת. בכך, הם משפרים את רמת השירות התחבורתי במרחב העירוני והבין-עירוני כאחד.

כדי להבין כיצד ניתן לשפר את יעילות הצמתים המרומזרים, חשוב להכיר את האלגוריתמים הנפוצים המשמשים כיום לניהול תנועת הרמזורים. אלגוריתמים אלה מהווים את הבסיס לפעולת הרמזורים ומשפיעים ישירות על זרימת התנועה בצומת. הבנת המנגנונים הקיימים תאפשר להצביע על המגבלות שלהם ולהציע פתרונות מתקדמים יותר לניהול אופטימלי של התנועה.

להלן אלגוריתמים נפוצים של צמתים מרומזרים:

1. אלגוריתם אורך מחזור קבוע:

באלגוריתם זה, רמזורים עוקבים אחר אורך מחזור קבוע, שהוא הזמן הכולל שלוקח לרמזור להשלים רצף מלא של שלבים (ירוק, צהוב, אדום). לכל שלב יש משך זמן קבוע המוגדר מראש.

2. אורך מחזור לפי שעות היום:

חלק ממערכות הזמן הקבועות עשויות להיות תוכניות תזמון שונות לשעות שונות ביום, כגון שעות שיא לעומת שעות עם מעט תנועה בכבישים. תוכניות אלה מתוכננות כמו אלגוריתם אורך מחזור קבוע אבל אורך המחזור וחלוקת ה"צבעים" של הרמזור במחזור זה משתנים לפי השעה ביום בזמנים מוגדרים מראש.


עם חלוף השנים הטכנולוגיות התפתחו והחלו לצוץ אלגוריתמים דינמיים לשליטה על התנועה ובהם:

3. שימוש בלולאות אינדוקטיביות (inductive loop):

שימוש בלולאות אינדוקטיביות (תמונה 1) מסייע במדידת צפיפות התנועה על ידי זיהוי נוכחות כלי רכב על הכביש. לולאות אינדוקטיביות ממוקמות באופן אסטרטגי לאורך רוחב הכביש בשני מיקומים לכל נתיב. כאשר רכב עוצר מעל לולאות אלו באור אדום, מעגל גלאי הלולאה מופעל, המעיד על נוכחותו. על ידי ניתוח הפלט של לולאות אלו, המערכת יכולה לקבוע את רמת צפיפות התנועה בנתיבים השונים, ולסווג אותה לפי העומס.

לולאות אינדוקטיביות יעילות למדידת צפיפות התנועה מכיוון שהן מספקות נתונים בזמן אמת על נוכחות הרכב ותנועתו. המערכת יכולה להשתמש במידע זה כדי להתאים את אותות הרמזורים, לתעדף נתיבים עם עומס גבוה יותר ולייעל את זרימת התנועה. בנוסף, לולאות אינדוקטיביות הן חסכוניות, עמידות בפני גורמים סביבתיים, מה שהופך אותן לשיטה אמינה לניהול תעבורה.

בסך הכל, השימוש בלולאות אינדוקטיביות ככלי למדידת צפיפות התנועה מציע פתרון מעשי ויעיל למערכות בקרת תנועה, המאפשר לרשויות לקבל החלטות מושכלות לשיפור הבטיחות בדרכים והפחתת העומס.



תמונה 1: מערכת לולאה אינדוקטיבית

4. שימוש בעיבוד תמונה:

מערכות בקרת תנועה מהדור החדש מבוססות על טכנולוגיות מתקדמות של עיבוד תמונה בזמן אמת, המהוות פריצת דרך ביחס לשיטות המסורתיות. מערכות אלו משתמשות במצלמות דיגיטליות המוצבות בצמתים לצורך ניטור רציף של התנועה, תוך ניתוח חכם של הווידאו באמצעות אלגוריתמים של ראייה ממוחשבת ולמידת מכונה.

באמצעות טכנולוגיה זו, ניתן לזהות בזמן אמת את מספר כלי הרכב, את מהירות נסיעתם, ואף להבחין בין סוגי כלי רכב – כולל הולכי רגל, אופנועים, כלי רכב פרטיים, משאיות ואף רכבי חירום כמו אמבולנסים, ניידות משטרה וכבאיות. זיהוי זה מאפשר למערכת להגיב באופן דינמי ולתעדף נתיבים על פי צפיפות התנועה, במטרה למנוע עומסים מיותרים ולשפר את זרימת התנועה. אחד היתרונות הבולטים של מערכות עיבוד תמונה מתקדמות הוא היכולת להעניק עדיפות אוטומטית לרכבי חירום, ללא צורך בתקשורת ישירה ביניהם לבין מערכת הרמזורים. בניגוד לשיטות המסורתיות – כמו לולאות השראה או חיישנים מגנטיים – שלרוב אינן מזהות את סוג הרכב, המצלמה החכמה מסוגלת לזהות את כלי הרכב לפי מאפיינים ויזואליים, ולהתאים את מצב הרמזור בהתאם, באופן מהיר ומדויק.

יתרון נוסף הוא שעלות ההטמעה והתחזוקה של מערכת מבוססת עיבוד תמונה יכולה להיות נמוכה יותר, שכן היא אינה דורשת התקנת תשתית פיזית כבדה בתוך הכביש, כגון לולאות השראה הטמונות באספלט. במקום זאת, המצלמה מותקנת מעל הצומת או בצידו, ולעיתים ניתן להשתמש אף במצלמות קיימות, תוך שילוב תוכנה מתקדמת בלבד. כך מתקבלת מערכת חסכונית, גמישה וקלה לפריסה, במיוחד באזורים עירוניים קיימים.

לסיכום, שילוב עיבוד תמונה בזמן אמת במערכות בקרת רמזורים מהווה פתרון מתקדם, חסכוני ודינמי, אשר תורם לייעול התנועה, לשיפור הבטיחות ולהנגשת תנועה חלקה ויעילה גם בתנאים משתנים ובמקרי חירום.

1.1.1 היבט חברתי

הבעיה שאנו מנסים לפתור מתמקדת במערכת ניהול תנועת הרכב והולכי הרגל בצומת תעבורה עם שימוש בטכנולוגיה חכמה ולמידת מכונה. ניתן לזהות מספר השלכות חברתיות של הפתרון הטכנולוגי המוצג:

שיפור נגישות ובטיחות בדרכים: שימוש במערכת כזו מקנה שליטה מרוחקת ואוטומטית על תנועת הרכב והולכי הרגל בצומת, דבר היכול להוביל לשיפור נגישות הדרכים ולהפחתת תאונות. השיפור בבטיחות נובע מיכולת המערכת לזהות את המכוניות והולכי הרגל בזמן אמת ולקבוע את החלטות התעבורה בהתאם.

שיפור זרימת התנועה והיעילות העירונית: באמצעות שימוש באלגוריתמים של למידת מכונה, ניתן להפחית עיכובים ולשפר את זרימת התנועה בצומת. כך, ניתן לחסוך זמן נסיעה ולהפחית את התופעה של עיכובי תנועה, שיכולה לשפר את חוויית הנסיעה ולהפחית את התסכול של הנהגים.

אתיקה ופרטיות: השימוש במצלמות ובאלגוריתמים לזיהוי כלי רכב והולכי רגל עלול לגרום לחששות בנושא הפרטיות והאתיקה. יש להבטיח כי הנתונים האישיים שנאספים יאספו בצורה שמגנה על הפרטיות של האנשים המעורבים (לדוגמה ע"י טשטוש הפנים של הולכי הרגל לפני שליחת התמונה לשרת). מערכות כאלה צריכות להקפיד על התאמה לתקנות הפרטיות ועל מנגנונים לאבטחת נתונים.


לסיכום, השימוש בטכנולוגיה כזו בניהול תנועת הרכב והולכי רגל בצומת יכול להביא לשיפור ניכר בבטיחות, נגישות ויעילות התנועה, אך דורש גם עיון מקיף בהשלכות החברתיות והאתיות של הטכנולוגיה על החברה כולה.

1.1.2 היבט מדעי

למידת חיזוקים (reinforcement learning - RL) היא תחום מרכזי בלמידת מכונה, אשר עוסק באימון של סוכנים (agents) הפועלים בתוך סביבה (environment), תוך מטרה ללמוד מדיניות פעולה אופטימלית על סמך אינטראקציה חוזרת עם הסביבה (תמונה 2). בניגוד ללמידה מפקחת (supervised learning), שבה הסוכן לומד מתשובות נכונות שסופקו מראש, למידת חיזוקים מבוססת על ניסוי וטעייה – הסוכן מבצע פעולות, מקבל חיזוק חיובי או שלילי (reward/penalty), ומעדכן את מדיניותו בהתאם.

מרכיבים בסיסיים של מערכת RL:

1. **הסוכן (Agent):** הישות הלומדת, שמבצעת פעולות על פי מדיניות מסוימת.
2. **הסביבה (Environment):** המרחב שבתוכו פועל הסוכן – יכולה להיות וירטואלית (כמו סימולציה) או פיזית (כמו רובוט).
3. **מצב (State):** תיאור הנוכחי של הסביבה כפי שהסוכן "רואה" אותו.
4. **פעולה (Action):** צעד שננקט על ידי הסוכן מתוך קבוצת פעולות אפשריות.
5. **תגמול (Reward):** ערך מספרי שמייצג את איכות הפעולה שביצע הסוכן. תגמול גבוה מאותת על פעולה טובה, שלילי – על פעולה לא רצויה.
6. **מדיניות (Policy):** אסטרטגיית הפעולה של הסוכן – פונקציה שקובעת איזו פעולה תתבצע בכל מצב.
7. **פונקציית ערך (Value Function):** מעריכה את ערכו של מצב או של פעולה – כלומר, כמה תגמול צפוי בעתיד מהמצב הנוכחי.



תמונה 2: אינטרקציה הסוכן עם הסביבה בשיטת למידת חיזוקים

שיטות עיקריות בלמידת חיזוקים (RL)

Q-Learning:

Q-Learning היא טכניקת למידה ללא מודל (model-free), שבה הסוכן לומד פונקציית ערך הקרויה Q, המתארת את התועלת הצפויה של פעולה מסוימת במצב נתון. במהלך הלמידה, הסוכן מעדכן את ערכי ה-Q על פי חוויות מהסביבה. ברגע שסיים ללמוד, ניתן לגזור מדיניות אופטימלית על ידי בחירת הפעולה עם ערך ה-Q הגבוה ביותר בכל מצב.

Deep Reinforcement Learning:

במערכות מורכבות יותר, שבהן מרחב המצבים או הפעולות גדול או רציף, קשה לאחסן ערכי Q בטבלה. כאן נכנס לשימוש למידת חיזוקים עמוקה, שבה משתמשים ברשתות נוירונים כדי לאמוד את פונקציית Q או את המדיניות ישירות. DRL מאפשר פתרון בעיות בממדים גבוהים ובסביבות ריאליסטיות מאוד, כולל משחקים, רובוטיקה, מערכות בקרה מתקדמות, תכנון תחבורה ועוד.

Policy Gradient Methods:

בשיטות אלו, הסוכן לומד את המדיניות ישירות, באמצעות גרדיאנט (נגזרת) של פונקציית התגמול המצטבר ביחס לפרמטרי המדיניות. שיטה זו נחשבת יציבה יותר במקרים שבהם מרחב הפעולות הוא רציף, או כאשר יש צורך במדיניות סטוכסטית (אקראית).

יתרונות למידת חיזוקים

1. **למידה עצמאית:** הסוכן לא זקוק לנתונים מסומנים מראש – הוא לומד בעצמו, דרך אינטראקציה עם הסביבה.
2. **התמודדות עם חוסר ודאות:** שיטות RL מצטיינות בטיפול בסביבות שבהן יש חוסר ודאות, תנאים משתנים ותגובות מורכבות.
3. **קבלת החלטות רציפה:** ניתן ליישם RL לתהליכים מתמשכים או מחזוריים (כמו ניהול תנועה, מערכות המלצה, שוקי מניות וכו').
4. **גמישות והסתגלות:** המודל ממשיך ללמוד גם לאחר שלב האימון, וכך מסתגל לשינויים בזמן אמת.

לפני פריסת המערכת בסביבה ממשית, סוכן למידת החיזוק מתאמן בסימולציה ממוחשבת מתקדמת, המדמה את פעולת הצומת באופן ריאליסטי. הסימולציה כוללת מודל מדויק של מבנה הצומת, כלי רכב, רמזורים ודפוסי תנועה מגוונים.

המערכת מתנסה במצבים שונים – החל מזרימת תנועה שוטפת ועד לעומסי שיא ומקרי קצה – כדי להבטיח עמידות ויכולת תגובה גם בתנאים חריגים. ניסויים אלו מאפשרים בחינה מבוקרת של תגובות הסוכן לסיטואציות מורכבות וניתוח ביצועים לאורך זמן.

בעבודה זו להערכת ביצועי הסוכן, הוגדרו מדדי ביצוע כמותיים, כגון: מספר כלי הרכב שעברו את הצומת בפרק זמן נתון, משך ההמתנה הממוצע, ומידת השיפור בזרימת התנועה לעומת שיטות מסורתיות. מדדים אלה מספקים בסיס להשוואה אובייקטיבית בין תרחישים שונים ובין גישות ניהול שונות.

לאחר הצלחה בשלב הסימולציה, נעשה המעבר לשלב ההטמעה הפיזית. בשלב זה, הסוכן מקבל קלט ממצלמות חכמות אמיתיות, והאלגוריתם מותאם לתנאי השטח, כולל התמודדות עם רעשים, שינויים בתאורה, תנאי מזג אוויר, ובלתי ודאויות אחרות הקיימות במציאות.

פרויקט זה מדגים את הפוטנציאל המדעי בשימוש בלמידת חיזוקים וראיית מחשב לניהול תשתיות תחבורה. באמצעות פיתוח סוכן חכם ואימון בסימולציה מתקדמת, המערכת מציעה פתרון יעיל, דינמי ומבוסס נתונים לניהול צמתים עירוניים.


1.1.3 היבט טכנולוגי

ההיבט הטכנולוגי של הפרויקט מתמקד בטכנולוגיות המתקדמות הנדרשות לניהול חכם של צומת תנועה באמצעות למידת חיזוק, זיהוי עצמים וניתוח נתונים בזמן אמת. בפרק זה נסקור את הטכנולוגיות הרלוונטיות לפרויקט.

זיהוי עצמים באמצעות ראיית מחשב

בבסיס הפרויקט עומדת מערכת לזיהוי עצמים המבוססת על מצלמות המותקנות בצומת. הטכנולוגיה כוללת את המרכיבים הבאים:

- **מצלמות:** מצלמות ברזולוציה גבוהה המותקנות בצומת כדי ללכוד תמונות בזמן אמת.
- **רשתות נוירונים קונבולוציוניות (CNN):** משמשות כבסיס לעיבוד וזיהוי תמונה במערכות ראייה ממוחשבת (תמונה 3). מודלים מתקדמים כמו YOLO ו-SSD, הבנויים על גבי CNN, מאפשרים זיהוי עצמים בזמן אמת בתמונות ווידאו – ובכך מתאימים במיוחד ליישומים כמו ניתוח תנועה בצמתים חכמים.



תמונה 3: דוגמא לזיהוי מכוניות על ידי רשתות נוירונים קונבולוציוניות

סימולציות תנועה

הפרויקט מתבסס על סימולציות תנועה מתקדמות לאימון הסוכן לפני פריסה בעולם האמיתי:

- **צומת מודולרית:** עבור כל גורם בצומת קיים מודל המחקה את התנהגותו (כלי רכב, כבישים, צמתים). קובץ מרכזי מנהל את כל האובייקטים למען שליטה נוחה וברורה בסימולציה.

בפרויקט זה נעשה שימוש ברכיבי חומרה כמו Raspberry Pi ו-ESP32 לצורך שליטה וניהול של סימולציה פיזית של הצומת. חיבור בין רכיבים אלו יבוצע באמצעות פרוטוקול UART, המאפשר תקשורת נתונים פשוטה, אמינה ומהירה בין מכשירים.

Raspberry Pi

- **בקר מרכזי:** ה-Raspberry Pi ישמש כבקר המרכזי לניהול הסימולציה הפיזית. הוא יקבל נתונים מהמצלמות וממערכת זיהוי העצמים, ויבצע עיבוד מקומי כדי להפעיל את הרמזורים.
- **חיבור למצלמות:** ה-RPI יחובר למצלמות חכמות שיקליטו את התנועה בצומת, ולאחר מכן יעבד את הנתונים ויקבל החלטות לגבי ניהול הרמזורים.

ESP32

- **ניהול רמזורים:** ה-ESP32 ישמש לבקרה על פעולת הרמזורים בסימולציה. רכיב זה, שהוא מיקרו-בקר חכם, יקבל פקודות מה-RPI דרך UART ויבצע את ההוראות להפעלת הרמזורים בהתאם להחלטות שהתקבלו.
- **חיישנים נוספים:** ה-ESP32 יכול גם להתחבר לחיישנים נוספים בסימולציה, כמו גלאי תנועה או חיישני קרבה, כדי לספק מידע נוסף לשיפור ההחלטות.

תקשורת UART

- **פרוטוקול תקשורת:** UART ישמש לתקשורת סינכרונית בין ה-RPI ל-ESP32. היתרונות של UART כוללים פשטות בהתקנה, יעילות בהעברת נתונים ישירה, וחיסכון במשאבים.
- **אמינות ואינטגרציה:** באמצעות UART, התקשורת בין ה-RPI ל-ESP32 תהיה יציבה ואמינה, מה שמאפשר אינטגרציה חלקה בין הבקר המרכזי למיקרו-בקר.

שימוש בטכנולוגיות אלו יאפשר ליצור סימולציה פיזית ריאליסטית של צומת, שבה נבחן את תפקוד המערכת המוצעת בזמן אמת.

לסיכום, פרויקט זה משלב טכנולוגיות מתקדמות בראיית מחשב, למידת חיזוקים וניהול נתונים בזמן אמת. שילוב של כלים וטכנולוגיות אלה מאפשר יצירת מערכת חכמה ואוטונומית לניהול צמתים, המסוגלת להתמודד עם אתגרים של תנועה עירונית בצורה יעילה ובטוחה.

1.2 הבעיות העיקריות במצב הקיים

אחד האתגרים המרכזיים בערים מודרניות הוא ניהול התנועה בצמתים. צמתים, שהם נקודות המפגש של זרמי תנועה שונים, עלולים לגרום לעומסי תנועה משמעותיים, בעיקר בשעות השיא. ניהול לא יעיל של צמתים באמצעות רמזורים שאינם חכמים דיים מהווה גורם מרכזי לבעיה זו, ויוצר מספר השלכות חמורות:

1. עיכובים מוגברים וזמן נסיעה ממושך

רמזורים שאינם מותאמים בזמן אמת למצב התנועה מאלצים כלי רכב להמתין בצומת גם כאשר אין בכך צורך. מערכות רמזורים רבות פועלות לפי תוכניות קבועות מראש, מבלי להתחשב בכמות כלי הרכב בכל נתיב, בשינויים בזמן אמת, או בהשפעת העומס בצמתים סמוכים. כתוצאה מכך:

- כלי רכב מבליים זמן רב יותר על הכביש.
- נוצרים פקקי תנועה שניתן היה למנוע עם תכנון חכם יותר.
- השחיקה במערכות הרכב (לדוגמה, מנוע ובלמים) גוברת עקב העצירות המרובות.

2. עלייה בזיהום האוויר

עיכובים מיותרים בצמתים מובילים לשימוש מוגבר בדלק, במיוחד בזמן שהמנוע עובד במצב סרק (idle). כך נגרמת עלייה בפליטת מזהמים כגון פחמן דו-חמצני (CO_2) וחלקיקים רעילים נוספים. על פי מחקרים, כלי רכב העומדים זמן רב בצמתים תורמים משמעותית לזיהום האוויר העירוני, המשפיע לרעה על בריאות הציבור ועל איכות החיים.

3. בזבז משאבים כלכליים

פקקי תנועה אינם רק מטרד אישי; יש להם השלכות כלכליות נרחבות. זמן ההמתנה בצמתים עולה למשק כסף רב, הן באופן ישיר (בזבז דלק) והן באופן עקיף (אובדן זמן עבודה, עיכובים בשירותים לוגיסטיים ופגיעה באפקטיביות של התחבורה הציבורית).

4. פגיעה בבטיחות

רמזורים שאינם מותאמים בזמן אמת עלולים ליצור מצבים מסוכנים בצמתים. לדוגמה:

- מצבים בהם נתיב ריק מקבל אור ירוק בעוד נתיב עמוס ממשיך להמתין.
- נהגים חסרי סבלנות עלולים לקחת סיכונים כמו חציית צומת באור אדום, מה שמגביר את הסיכון לתאונות.

גורמים לבעיה

- **מערכות ישנות:** מרבית הרמזורים אינם מחוברים למערכות חכמות או מבוססות בינה מלאכותית שיכולות לאסוף נתוני תנועה בזמן אמת.
- **חוסר אינטגרציה:** רמזורים בצמתים סמוכים אינם מתקשרים זה עם זה כדי ליצור תנועה חלקה.
- **העדר השקעה בתשתיות:** רשויות רבות מעדיפות פתרונות זולים וקלים ליישום במקום השקעה במערכות חדשניות ויעילות לטווח ארוך.

על פי דוח של *Forbes* משנת 2014, גודש תנועה עולה לאמריקאים 124 מיליארד דולר בשנה. מחקרים באיחוד האירופי מעריכים את עלות גודש התנועה בכ-1% מהתמ"ג. המערכת הנוכחית לניהול צמתים אינה מותאמת לעומסי התנועה של המאה ה-21. שילוב של טכנולוגיות חכמות כגון למידת חיזוקים ושימוש במידע בזמן אמת עשויים להוות פתרון יעיל לשיפור זרימת התנועה, הפחתת זיהום האוויר ושיפור איכות החיים בערים מודרניות.

הנתונים הללו מצביעים על הצורך הדחוף בשיפור מערכות ניהול התנועה הנוכחיות. למרות זאת, האלגוריתמים הנפוצים כיום לניהול רמזורים בצמתים מבוססים על תבניות זמן קבועות או כללים סטטיים, שאינם מתחשבים בשינויים הדינמיים בעומסי התנועה בזמן אמת. גישה זו מגבילה את היכולת של המערכת להגיב ביעילות לשינויים בלתי צפויים בתנועה, מה שמוביל להארכת זמני הנסיעה, עלייה בזיהום האוויר ועיכובים מיותרים.

למרות היתרונות של שיטות ניהול תנועה קיימות, חסרונותיהן מדגישים את הצורך בשיפור ובאימוץ טכנולוגיות מתקדמות. הבנת המגבלות של האלגוריתמים הנוכחיים היא קריטית לזיהוי תחומים בהם ניתן לשפר את היעילות והדיוק של בקרת התנועה. בכל אחד מהאלגוריתמים הקיימים (אשר הוצגו ב-1.1) קיימים מספר חסרונות, המפורטים להלן:

1. אורך מחזור קבוע

חוסר הסתגלות: אחד החסרונות העיקריים הוא היעדר הסתגלות לתנאי התנועה בזמן אמת. מכיוון שאורך המחזור קבוע, הרמזורים לא יוכלו להסתגל לשינויים פתאומיים בזרימת התנועה, דבר שיוביל לעומסים או עיכובים אפשריים.

חוסר יעילות: אם משכי הזמן שנקבעו מראש עבור כל שלב בתוך המחזור אינם ממוטבים בהתבסס על דפוסי תנועה בפועל, תיגרם חוסר יעילות. לדוגמה, משך אור ירוק ארוך עבור נתיב עם תנועה מינימלית עלול לגרום לזמני המתנה מיותרים לנתיבים אחרים.

גמישות מוגבלת: ייתכן שמערכות באורך מחזור קבוע לא יוכלו להכיל אירועים מיוחדים, סגירת כבישים או מצבי חירום ביעילות. התאמת אורך המחזור או חלוקת השלבים תוך כדי תנועה יכולה להיות מאתגרת בגישה זו.

2. אורך מחזור לפי שעות היום

מורכבות: ניהול תוכניות תזמון מרובות בשעות שונות ביום יכול להכניס מורכבות למערכת. הבטחת מעברים חלקים בין תוכניות שונות מבלי לגרום לשיבושים או בלבול לנהגים יכולה להוות אתגר.

סנכרון: תיאום המעבר בין תוכניות תזמון שונות בצורה חלקה בזמנים מוגדרים מראש יכול להיות מסובך. אם לא מסונכרן כראוי, זה עלול להוביל לצווארי בקבוק בתנועה או לבילבול עבור הנהגים.

תחזוקה: עדכון ותחזוקה שוטפת של תכניות התזמון בהתאם לדפוסי התנועה המשתנים ולתנאי הדרך עלולים לגזול זמן ומשאבים.

3. שימוש בלולאות אינדוקטיביות

בעוד שלולאות אינדוקטיביות מציעות יתרונות רבים במערכות בקרת תעבורה, יש גם מספר חסרונות פוטנציאליים שיש לקחת בחשבון:

מורכבות: תכנות וקביעת תצורה של לולאות אינדוקטיביות למשימות ספציפיות עשויות להיות מורכבות ודורשות ידע ומיומנויות מיוחדות. מורכבות זו עלולה להוביל לאתגרים באינטגרציה ובתחזוקה של המערכת.

עלות: הטמעת מערכת מבוססת לולאות אינדוקטיביות עשויה להיות כרוכה בעלויות ראשוניות גבוהות יותר בהשוואה לשיטות בקרת תעבורה מסורתיות. עלות זו כוללת את עלות החומרה, פיתוח תוכנה ותמיכה שוטפת.

מדרגיות: הרחבה או שינוי של מערכת בקרת תעבורה מבוססת לולאות אינדוקטיביות כדי להתאים לדפוסי תעבורה משתנים או שדרוגי תשתית עשויים לדרוש זמן ומשאבים משמעותיים.

אבטחה: כמו בכל מערכת דיגיטלית, מערכות בקרת תעבורה מבוססות לולאות אינדוקטיביות עשויות להיות פגיעות לאיומי סייבר וניסיונות פריצה. אבטחת המערכת חיונית כדי למנוע גישה או מניפולציה בלתי מורשית.

4. עיבוד תמונה

בעוד שעיבוד תמונה או וידאו בזמן אמת מציעים מספר יתרונות בבקרת אותות תנועה, יש גם כמה חסרונות פוטנציאליים שיש לקחת בחשבון:

מורכבות: הטמעת מערכות עיבוד וידאו בזמן אמת עשויה להיות מורכבת ודורשת מומחיות מיוחדת בחומרה ובתוכנה. מורכבות זו עשויה להוביל לעלויות התקנה ראשוניות גבוהות יותר ולדרישות תחזוקה.

זמן עיבוד: עיבוד וידאו בזמן אמת יכול לגרום לעיכובים בקבלת החלטות עבור בקרת איתות תנועה, במיוחד במצבים עם עומס תנועה כבד או תנאי כביש מורכבים. עיכובים בעיבוד עלולים להשפיע על יכולת המערכת להגיב במהירות לדפוסי תנועה משתנים.

אמינות: מערכות עיבוד וידאו/תמונה עשויות להיות רגישות לשגיאות או אי דיוקים, במיוחד בתנאי מזג אוויר מאתגרים כגון גשם, ערפל או תאורה לקויה. הבטחת האמינות והדיוק של המערכת בכל הנסיבות היא חיונית לשליטה יעילה באותות התנועה.

פרטיות: השימוש במצלמות לעיבוד תמונה מעלה חששות לגבי הפרטיות הקשורות למעקב ואיסוף נתונים. הבטחת עמידה בתקנות הפרטיות והתייחסות לדאגות הציבור לגבי אבטחת מידע ומעקב היא חשובה בעת יישום מערכות כאלה.

עלות: עשויות להיות עלויות משמעותיות הקשורות להגדרה, תחזוקה ותפעול שוטף של מערכות עיבוד תמונה ועיבוד וידאו בזמן אמת. יש לשקול בקפידה עלויות אלו בהשוואה ליתרונות שמספקת המערכת.

1.3 פתרונות קיימים בתחום

NoTraffic-1.3.1

חברת NoTraffic מציעה מערכת שניתנת להתקנה תוך שעות ספורות בכל צומת מרומזר. היא מציידת את הרמזור במצלמה, מכ"ם, רכיב תקשורת ומעבד. כל אלה הופכים אותו לרמזור "חכם", אשר יודע, באמצעות אלגוריתמים של בינה מלאכותית, לסווג את משתמשי הדרך למכוניות, אוטובוסים, רוכבי אופניים, קורקינטים, אופנועים, הולכי רגל ואפילו אנשים המתניידים בכיסא גלגלים, לחשב את זמני ההגעה המשוערים של כל אחד ואחד מהם אל הצומת, ולתזמן את חילופי הצבעים ברמזור. כאשר המערכת פרוסה על פני כמה צמתים ברחבי העיר, נוצרת "רשת" של רמזורים שמתקשרים ביניהם ומסתנכרנים באופן המיטבי ביותר כך שהתנועה תזרום.

ITC-1.3.2

חברת ITC - חברת ITC מביאה איתה דרך חדשנית ואדפטיבית לשליטה ברמזורים.

"אנחנו עושים ניתוח לכל מה שקורה מסביב: כמה כלי רכב עוברים ברמזור, מאיזה סוג, מה התאוצה שלהם, התאוצה ושמירת המרחק. את כל הנתונים האלה אנחנו מנתחים ויש לנו אלגוריתם שיועד לחזות מה יקרה בצומת בדקות הקרובות.", מסביר אהרון ברונר מ-ITC.

המערכת של ITC פועלת בשלבים הבאים:

1. איסוף נתונים באמצעות מצלמה – המצלמה מזהה את תנועת כלי הרכב בצומת, כולל מספר כלי הרכב, סוגי כלי הרכב (פרטיים, אוטובוסים, אופנועים וכו'), מהירותם, תאוצתם, בלימתם, ושמירת המרחק ביניהם.
2. שליחת נתונים לענן – הנתונים שנקלטים מהמצלמה מועברים אל שרתי הענן של החברה, שם מתבצע עיבוד מתקדם.
3. ניתוח ותחזית תנועה – אלגוריתם מתקדם מנתח את המידע שנאסף ויוצר תחזית של המצב בצומת בדקות הקרובות. כך המערכת לא רק מגיבה למצב הנוכחי, אלא גם מסוגלת לצפות שינויים בתנועה ולהיערך בהתאם.
4. שליחת פקודות לרמזורים – על בסיס התחזיות, המערכת מחליטה על הפעולה האופטימלית ומעבירה פקודות ישירות לרמזורים, תוך התאמה דינמית של זמני הרמזור בהתאם לתנאי התנועה בזמן אמת.

2. תהליך המחקר והפיתוח

2.1 ניתוח מרחב הבעייה ומרחב הפתרונות

התופעה: גודש תנועה בצמתים

גודש התנועה בצמתים הוא בעיה נפוצה בערים גדולות, במיוחד בשעות השיא. התופעה מתרחשת כאשר מספר כלי הרכב החוצים את הצומת עולה על יכולת הקיבול שלו, מה שגורם לעיכובים, ירידה במהירות התנועה, ולעיתים אף פקקים ארוכים. הגודש בצמתים גורם לשורה של בעיות, שיפורטו להלן.

בעיה	גורמים	השלכות
עיכובים וזמני נסיעה ארוכים	תזמון לא יעיל של הרמזורים, עלייה במספר כלי הרכב, ותקלות טכניות בצומת.	נהגים נאלצים להמתין זמן רב יותר בצומת, מה שמוביל לירידה ביעילות הנסיעה ולהפסד זמן.
צריכת דלק מוגברת וזיהום אוויר	עצירות תכופות, האצות חוזרות ונשנות ושהייה במצב סרק גורמות לכלי רכב לצרוך יותר דלק.	עלייה בפליטת גזי חממה ומזהמים אחרים, הפוגעים באיכות האוויר ובריאות הציבור.
תאונות דרכים	עומסי תנועה עלולים לגרום לנהגים לחוסר להחלטות פזיזות, כגון חציית צומת באור אדום.	עלייה בסיכון לתאונות דרכים, במיוחד בהתנגשויות בין כלי רכב להולכי רגל.
בזבז אנרגיה ופגיעה בכלכלה	כלי רכב הממתינים בצומת צורכים יותר דלק, וכתוצאה מכך יש בזבז של משאבים.	עלויות דלק גבוהות יותר לנהגים, הפסדים כלכליים גדולים יותר למשק, וזמן עבודה מבזבז.
חוויית נסיעה שלילית ותסכול הנהגים	הצטברות של עיכובים וחוסר שליטה על מצב התנועה גורמים לתחושת תסכול אצל הנהגים.	תחושת אי שביעות רצון כללית מהתחבורה הציבורית והפרטית.

פתרונות:

שיפור תזמון הרמזורים

תזמון הרמזורים מתבצע באופן דינמי תוך שימוש באלגוריתמים חכמים המנתחים את תנועת כלי הרכב בזמן אמת. מערכת זו מאפשרת התאמה מדויקת של מחזורי הרמזור בהתאם לעומס התנועה בפועל – ובכך מפחיתה זמני המתנה ומשפרת את הזרימה בצומת.

ניהול חכם של התנועה

שילוב בין מצלמות לזיהוי עצמים לבין סוכני למידת חיזוק מאפשר ניהול אקטיבי, אדפטיבי ואוטונומי של התנועה. הסוכן מקבל החלטות מבוססות נתונים לגבי העדפת כיווני נסיעה שונים, בהתאם לצפיפות הרכב והתנאים המשתנים בזמן אמת.

קידום תחבורה ציבורית

המערכת תומכת בעידוד השימוש בתחבורה ציבורית, על ידי הקצאת עדיפות לאוטובוסים וכלי רכב ציבוריים בצמתים. כך מתאפשרת הגעה מהירה יותר של אמצעי תחבורה המוניים, תוך הפחתת העומס הנגרם מכלי רכב פרטיים.

מודלים לערים חכמות

יישום גישה של תכנון עירוני חכם, המתמקד בהנגשת תחבורה ציבורית ויצירת חלופות לרכב פרטי. שילוב טכנולוגיות תנועה חכמות כחלק מתשתיות העיר תורם להפחתת גודש התחבורה, זיהום האוויר ותלות ברכב פרטי.

מעקב וניתוח ביצועים

המערכת כוללת רכיבי ניטור מתקדמים שמבצעים מעקב שוטף אחר תפקוד הצומת. ניתוח נתונים סטטיסטיים – כמו זמן המתנה ממוצע, קצב מעבר כלי רכב, ועומסים חריגים – מאפשרים כווןן אוטומטי של מדיניות הרמזורים ושיפור מתמיד של ביצועי המערכת.

2.2 טבלת השוואה בין אפשרויות הפתרון

קריטריון	תזמון רמזורים סטטי מבוסס זמן	תזמון רמזורים דינמי מבוסס עומסים	סוכן למידת חיזוקים
יעילות בזרימת תנועה	בינונית	גבוהה	גבוהה מאוד – התאמה מתמדת ודינמית
עלות יישום ותחזוקה	נמוכה	בינונית	גבוהה בתחילה, אך משתלמת לאורך זמן
התאמה לטווח הארוך	מוגבלת	טובה	מצוינת – לומד, משתפר ומתאים עצמו
מורכבות טכנולוגית	נמוכה	בינונית	גבוהה – כולל ראיית מכונה ולמידה
גמישות לתנאים משתנים	נמוכה	בינונית	גבוהה מאוד – תגובה בזמן אמת
פוטנציאל עתידי	נמוך	בינוני	גבוה מאוד – בסיס למערכת חכמה רחבה

מסקנה

למרות עלות ההקמה והמורכבות הראשונית, סוכן למידת חיזוקים הוא הפתרון היחיד שמציע ניהול אקטיבי, אוטונומי ואדפטיבי של התנועה. זהו פתרון עתידי המשתלב עם מגמות של ערים חכמות ומספק שיפור משמעותי בתפקוד הצומת – לא רק עכשיו, אלא גם בהתמודדות עם תרחישים מורכבים בעתיד. הוא מהווה השקעה ארוכת טווח שמצדיקה את עצמה.

אסטרטגיות משלימות:

אסטרטגיה	תרומה למערכת	האם רלוונטית להשוואה ישירה?	הערה
קידום תחבורה ציבורית	מפחיתה את העומס הכללי על הצמתים	לא ישירה	משתלבת עם ניהול רמזורים חכם – לדוגמה, מתן עדיפות לאוטובוסים
מודלים לערים חכמות	מצמצמים את התלות ברכב פרטי	לא ישירה	מסגרת רחבה יותר, שבתוכה הטכנולוגיה באה לידי ביטוי
מעקב וניתוח ביצועים	מאפשר שיפור רציף ובקרה על כל פתרון	לא פתרון עצמאי	תנאי הכרחי לייעול מערכות רמזורים מתקדמות

נימוק הבחירה הסופית:

מתוך כלל האפשרויות שנבחנו, הפתרון מבוסס סוכן למידת חיזוק מציג את השילוב הטוב ביותר של ביצועים, אדפטיביות ויכולת התרחבות עתידית. בשילוב עם אסטרטגיות משלימות כמו תעדוף תחבורה ציבורית וניתוח ביצועים שוטף, מתקבלת מערכת חכמה שמביאה את ניהול הצמתים העירוניים לרמה חדשה לגמרי – גמישה, יעילה ומותאמת לעולם המשתנה במהירות.

3. מימוש הפתרון

3.1 מבנה המערכת שנבחרה

הפתרון שלנו כולל ניהול צומת תעבורה באמצעות סוכן למידת חיזוקים (Reinforcement Learning Agent), אשר אומן על סימולציה של הצומת ומסוגל לצפות במצב הצומת באמצעות מצלמת זיהוי עצמים. הפתרון נועד לשפר את זרימת התנועה בצומת על ידי התאמה דינמית של תזמון הרמזורים, בהתאם למצב התנועה בזמן אמת.

למערכת שני מצבים:

1. אימון הסוכן בסימולציה:

- הסוכן מתאמן בסביבה מדומה של הצומת, בה הוא לומד כיצד לשפר את זרימת התנועה ולמנוע עומסים.
- במהלך האימון, הסוכן מקבל חיזוקים חיוביים או שליליים בהתאם להצלחתו בהפחתת העיכובים בצומת.

2. הצבת הסוכן בצומת אמיתית:

- הסוכן המאומן מותקן במחשב RPI המחובר למצלמת זיהוי עצמים.
- המערכת עוקבת אחרי תנועת כלי רכב בצומת, מעבדת את המידע ומפעילה את הרמזורים בהתאם להחלטות הסוכן.

תיאור מצב 1:

עבור המצב הראשון והצגת המצב שני נדרשת סימולציה של צומת אשר תהווה את הסביבה בה הסוכן יפעל. סימולציה זו (תמונה 4) נדרשת להיות ריאליסטית ככל האפשר על מנת שהסוכן יאומן להתמודד עם מצבים אשר הגיוני כי יקרו במציאות.

הסימולציה אשר כתבנו בשפת **Python** מתארת תנועה עירונית, שבה כלי רכב נוצרים לאורך זמן, נוסעים לאורך כבישים ומגיבים לרמזורים. בלב המערכת נמצא אובייקט הסימולציה (**Simulation**), שהוא הגורם המרכזי שמנהל את כל מרכיבי המערכת: הכבישים, כלי הרכב, מחוללי כלי הרכב והרמזורים. תפקידו לעדכן את מצב הסימולציה בכל שלב של זמן — להזיז כלי רכב, להפעיל רמזורים, להוסיף כלי רכב חדשים ולהסיר כאלה שסיימו את מסלולם.

אחד המרכיבים העיקריים הוא **Road**, שמייצגת כביש בודד. כל כביש מחובר בין שתי נקודות במישור וכולל מידע כמו אורכו, כיוונו ורשימת כלי הרכב שנמצאים עליו כרגע. רשימה זו נשמרת בתור **Deque** כדי לייעל

את ההוספה וההסרה של כלי רכב בתחילת ובסוף הכביש. כל כביש עשוי לכלול רמזור, ואם כן — התנהגות כלי הרכב בו משתנה בהתאם למצב הרמזור שאליו הוא משויך.

כאן נכנסת לתמונה מחלקת `TrafficSignal`, שמייצגת רמזור קבוצתי — כלומר, כזה שמנהל קבוצות של כבישים שנכנסים לצומת מסוים. כל רמזור מקבל בעת יצירתו את רשימת קבוצות הכבישים שהוא שולט עליהם, וכן את מחזור האורות: רצף של מצבים בינאריים (אדום/ירוק) לכל קבוצה. נוסף על כך, הרמזור כולל פרמטרים פיזיים כמו מרחק האטה, מקדם האטה, ומרחק עצירה, אשר משפיעים על הדרך שבה כלי רכב מתקרבים אליו. בעת ההתחברות של הרמזור למערכת, הוא מעדכן כל כביש שהוא שולט עליו, כך שזה "יודע" שהוא נשלט על ידי הרמזור ומי קבוצת הבקרה שלו.


כאשר כביש מתעדכן (בקריאת `road.update`), הוא בודק את מצב הרמזור עבור קבוצת התנועה שלו. אם האור ירוק, הרכב המוביל (הראשון בתור) משוחרר מהמתנה, ושאר כלי הרכב מאיצים כרגיל. אם האור אדום, הכביש בודק האם הרכב המוביל נמצא עדיין במרחק שמאפשר לו לעצור בצורה בטוחה. אם כן — הוא מאט ואף נעצר בהתאם לצורך. רכב שכבר קרוב מדי לאזור העצירה לא יואט, כדי להימנע מעצירה פתאומית מסוכנת. כך, התגובה לרמזור היא דינמית ותלויה במיקום הרכב ובמצב האור.

הרכב עצמו, שמיוצג על ידי מחלקת `Vehicle`, נע לאורך מסלול קבוע המוגדר כרשימת אינדקסים של כבישים. כל רכב נמצא תמיד על כביש אחד בכל רגע, ומתקדם עליו לפי מהירותו ותאוצתו, תוך התחשבות במרחק מכלי רכב שלפניו ובמצב הרמזור. כאשר הוא מגיע לסוף הכביש, הסימולציה מעבירה אותו לכביש הבא במסלול, ואם סיים את המסלול — הוא מוסר מהמערכת.

בנוסף, הסימולציה כוללת את רכיב `VehicleGenerator`, שמייצר כלי רכב חדשים בקצב קבוע. כל רכב כזה מקבל מראש מסלול של כבישים, ומתווסף לתחילת הכביש הראשון שלו. בכך מתבצעת זרימה מתמדת של תנועה במערכת, המדמה תנועה עירונית רציפה.

האינטראקציות בין האובייקטים משתלבות יחד באופן טבעי: `Simulation` מפעיל את כל שאר הרכיבים, כולל עדכון של מצב הרמזורים (באמצעות `TrafficSignal.update`), יצירה של כלי רכב חדשים, ועדכון הכבישים וכלי הרכב עצמם. הכבישים מצידם יודעים לבדוק את מצב הרמזור המשוך להם בכל רגע, ולהשפיע בהתאם על התנועה בהם. כלי הרכב מגיבים לתנאי הדרך ולתנועה, והרמזורים מחליפים מצבים במחזוריות קבועה, תוך שליטה על זרימת התנועה בצמתים.

לסיכום, המערכת יוצרת סימולציה דינמית ואינטראקטיבית של תנועה עירונית, שבה לכל רכיב — כביש, רכב, רמזור או מחולל כלי רכב — יש תפקיד ברור ותיאום הדוק עם שאר מרכיבי המערכת. השילוב בין התנועה לאורך כבישים, תגובה חכמה לרמזורים ויצירה מתמדת של כלי רכב חדשים, מאפשר ליצור התנהגות ריאליסטית המדמה היטב את המציאות התחבורתית בעיר.

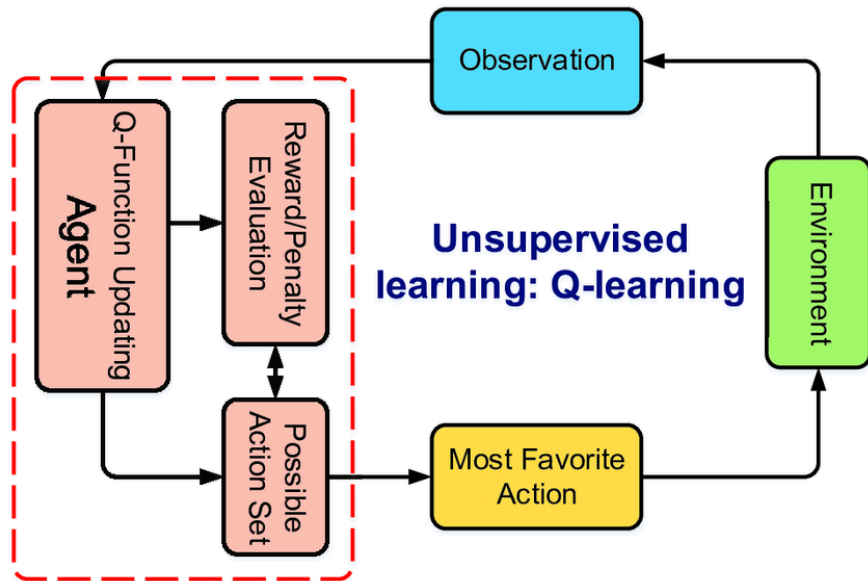


תמונה 4: דוגמא לסימולציה שפותחה במהלך הפרויקט

סוכן ה-QLearning (תמונה 5) פועל בלב מערכת הסימולציה ומשמש ככלי דינמי ללמידה ולשיפור תזמון פעולתם של הרמזורים. באמצעות תהליך של ניסוי וטעייה, ומדידה עקבית של איכות ההחלטות, הסוכן מצליח לבנות מדיניות פעולה חכמה שמובילה לזרימת תנועה טובה יותר. הסביבה עצמה מדמה באופן ריאליסטי תנועה עירונית מורכבת – עם כבישים, כלי רכב, רמזורים, האצות ותגובות, מה שמאפשר לאמן את הסוכן על בעיה שמדמה באופן קרוב את העולם האמיתי.

על מנת לאמן את הסוכן יש לבסס מספר הגדרות בסיסיות:

1. **מצב (State):** תיאור מצבו של הצומת - מיוצג ע"י מצב הרמזור הנוכחי, מספר כלי הרכב הנכנסים, ומשתנה בוליאני הקובע האם קיימים כלי רכב בתוך הצומת.
2. **פעולה (Action):** בחירת התמרור/הפאזה הבאה של הרמזור - מיוצג ע"י ערך סקלארי.
3. **תגמול (Reward):** ערך סקלרי המתקבל מהסביבה, שמעודד זרימת תנועה חלקה - תגמול עבור פעולה x מיוצג ע"י הפרש בין מספר כלי הרכב במצב x למספר כלי הרכב במצב $x+1$. הפרש חיובי גורף תגמול חיובי ולהפך.
4. **מדיניות (Policy):** פונקציה הממפה מצבים לפעולות - מיוצגת באופן אימפליציטי על ידי טבלת Q.



תמונה 5: אופן פעולת שיטת Q-learning

תהליך האימון:

האימון מתבצע לפי מתודולוגיית **episodic learning**, תוך כדי אינטראקציה של הסוכן עם הסביבה לאורך מספר אפיזודות. כל אפיזודה מייצגת סימולציה מלאה של זרימת תנועה בפרק זמן מסוים.

בכל אפיזודה:

1. **Reset**: הסביבה מאותחלת למצבה ההתחלתי.
2. **פעולה**: הסוכן בוחר פעולה על פי אסטרטגיית ϵ -greedy:
 - בהסתברות ϵ תיבחר פעולה אקראית (exploration).
 - אחרת, תיבחר הפעולה בעלת ערך ה-Q הגבוה ביותר (exploitation).
3. **תגובה**: הסביבה מחזירה את:
 - המצב החדש `next_state`
 - התגמול `reward`
 - דגל `done` אם הסתיימה האפיזודה
4. **עדכון**: הסוכן מעדכן את ערך ה-Q ע"פ נוסחת Q-Learning:

$$Q(s, a) \leftarrow (1 - \alpha) \cdot Q(s, a) + \alpha \cdot [r + \gamma \cdot a' \max_{a'} Q(s', a')]$$

כאשר:

- α — קצב הלמידה (learning rate)

○ γ — פקטור ההנחה (discount factor)

○ r — תגמול מיידי

○ s', a, s — מצב נוכחי, פעולה, ומצב חדש בהתאמה

5. **המשך הלמידה:** התהליך חוזר עד לסיום האפיזודה.

במהלך האימון, ערכי ה-Q הנלמדים על ידי הסוכן נשמרים לקובץ באמצעות הפונקציה `save_q_values`, דבר המאפשר טעינה מחדש של הידע שנרכש לטובת שלבי אימות או המשך למידה עתידיים. שימור זה מבטיח שלא תידרש למידת Q מחודשת בכל ריצה, ובכך חוסך משאבים חישוביים וזמן.

חשוב לציין כי במהלך האימון, הסוכן אינו פועל לפי מדיניות אופטימלית בלבד, אלא משלב גם חקירה פעילה של מרחב הפעולות והמצבים — לרוב לפי אלגוריתם ϵ -greedy. שילוב זה הכרחי כדי להימנע ממינימום מקומי ולהבטיח כיסוי רחב של המרחב האפשרי, במיוחד בשלבים המוקדמים של הלמידה, בהם ידע מוקדם כמעט ואינו קיים.

בשלב האימות (validation), הסוכן עובר הערכה מחודשת על אפיזודות חדשות, מבלי לבצע עדכונים לערכי ה-Q. מטרת שלב זה היא למדוד את ביצועי המדיניות שנלמדה בתנאים שלא נכללו באימון, ובכך להעריך את היכולת הכללית של הסוכן להכליל את ההתנהגות הנכונה. המדדים המרכזיים הנמדדים בשלב זה כוללים:

- **Average Waiting Time** — זמן המתנה ממוצע לרכב לאורך האפיזודה, המעיד על יעילות זרימת התנועה.
- **Collision Rate** — שיעור האפיזודות בהן התרחשו התנגשויות, כמדד לבטיחות הסימולציה.
- **Success Rate** — שיעור האפיזודות שהושלמו ללא התנגשויות, המהווה מדד לאמינות תפעולית.

מהבחינה המתודולוגית, הסוכן פועל תחת ההנחה שהסביבה מקיימת את עקרונות מודל מרקוב (Markov Decision Process), כלומר שהמעבר בין מצבים תלוי רק במצב הנוכחי ובפעולה הננקטת, ולא בהיסטוריה של המצבים הקודמים. המימוש הנוכחי של האלגוריתם מבוסס טבלת Q ואינו עושה שימוש ב-function approximation כמו רשתות נוירונים. לפיכך, הוא מתאים לבעיות בהן מרחב המצבים והפעולות דיסקרטי ובעל גודל סביר — תרחיש אופייני לניהול רמזורים בצמתים בהם מספר המצבים סופי ומוגדר היטב.

לבסוף, שימוש ב-`random.shuffle` בעת בחירת הפעולה האופטימלית מבטיח שבירה של סימטריה בין פעולות שונות אשר להן ערך Q זהה. פעולה זו חיונית להבטחת חקירה מגוונת לאורך זמן, ומונעת מהסוכן להעדיף עקביות שרירותית אשר אינה מבוססת על יתרון אמיתי. כך נשמרת מידה של אקראיות מבוקרת גם כאשר ערכי Q מתכנסים, מה שתורם ליציבות ויעילות הלמידה בטווח הארוך.


תיאור מצב 2:

בהצבת הסוכן המאומן בצומת אמיתית, נעשה שימוש במערכת משולבת הכוללת יחידת עיבוד (למשל Raspberry Pi), מצלמת זיהוי עצמים, ומנגנון בקרה אלקטרוני לרמזורים (תמונה 6). הסוכן, שאומן מראש על סימולציה של תזמון רמזורים, פועל בזמן אמת כדי לייעל את זרימת התנועה בצומת על בסיס נתוני חישה עדכניים.

בתחילת כל מחזור, מצלמת זיהוי העצמים המותקנת בצומת מצלמת את שטח הצומת ואת הדרכים המובילות אליו. באמצעות מודל זיהוי עצמים (כגון YOLO או OpenCV), המערכת מזהה את מיקומי כלי הרכב ומסירה מהם תכונות מצב הצומת: מספר כלי רכב בכל אחד מהכיוונים, מצב הרמזור הנוכחי, ואינדיקציה אם יש כלי רכב בתוך שטח הצומת עצמו. כל המידע הזה מעובד לייצוג אחיד של מצב (state), בפורמט שבו אומן הסוכן.

בהתאם למצב שנקלט, הסוכן מפעיל את מדיניותו — שהיא פונקציה שנלמדה במהלך האימון ומיוצגת כטבלת Q. הסוכן בוחר את הפעולה האופטימלית בהתאם לערכי ה-Q שנשמרו מהאימון. פעולה זו מייצגת את הבחירה של הפאזה הבאה של הרמזור — למשל, להמשיך בפאזה הנוכחית או לעבור לפאזה אחרת שמאפשרת תנועה מכיוון שונה.

לאחר קבלת ההחלטה, המחשב שולח פקודת בקרה למערכת הרמזורים — דרך ממשק חומרתי מתאים — והפאזה משתנה בהתאם להוראת הסוכן. תהליך זה חוזר על עצמו באופן מחזורי וקבוע: בכל כמה שניות נאספים נתונים חדשים, מצב הצומת מתעדכן, והסוכן מקבל החלטה חדשה.



תמונה 6: מבנה המערכת השלמה המותקנת בצומת

יישום פרקטי:

מכיוון שאין זה בא בחשבון להציג את יתרונות הסוכן בצומת אמיתית, נבנה מודל של צומת הנשלט ע"י הסימולציה והסוכן המאומן.

המודל כולל רמזור המורכב מ-12 נורות לד בצבעים המתאימים, שלוש לכל כיוון תנועה בצומת. בנוסף, מותקן פס לד מסוג Addressable הכולל 92 נורות, המדמה את תנועת כלי הרכב בכבישים. הפס מחולק ל-4 כיוונים (כביש דו-כיווני), 23 לדים לכל כיוון.

הרמזור מחובר לבקר ESP32 באמצעות הפינים הבאים:
13, 14, 26, 25, 33, 32, 15, 2, 4, 5, 18, 19 — פין אחד לכל נורת לד.

לעומת זאת, פס הלדים צורך זרם גבוה במיוחד:
($5520\text{mA} = 60 \times 92$) בהפעלה מלאה בצבע לבן בהיר (RGB: 255,255,255), דבר שה-ESP32 אינו מסוגל לספק בעצמו.

לכן, להפעלת פס הלדים נעשה שימוש בספק כוח חיצוני המספק מתח של 5 וולט וזרם מרבי של 30A, כך שיוכל לספק מתח יציב ובטוח גם בעומס מלא.

ה-ESP32 שולט בפס הלדים באמצעות פין D21, שמעביר את נתוני הצבעים והבהירות לכל לד בפס. שיטת התקשורת בין הבקר לפס הלדים היא Digital Serial Protocol, המתבצעת באמצעות ספריית NeoPixel.

שיטת התקשורת בין בקר ה-ESP32 לבין פס הלדים ה-addressable מבוססת על פרוטוקול סריאלי דיגיטלי חד-כיווני. מדובר בפרוטוקול ייחודי ורגיש לזמן, שבו הבקר שולח רצף של פולסים חשמליים (HIGH/LOW) באורכים מדויקים כדי לייצג את המידע עבור כל לד בפס.

עקרונות השיטה:

- כל לד בפס כולל **שבב בקר עצמאי**, הקולט את המידע המיועד אליו מתוך רצף הביטים שמגיע מהבקר.
- כל פקד מקבל **24 ביט (8 ביטים לכל אחד משלושת ערוצי הצבע RGB)**, לפי הסדר: Green – Red – Blue.
- לד הראשון בפס קורא את 24 הביטים הראשונים ושולח את השאר ללד הבא אחריו, וכן הלאה לאורך כל השרשרת.
- השליטה נעשית באמצעות **פין דיגיטלי בודד** (במקרה הזה, D21), מה שמוזיל ומפשט את החיווט.

תזמון הסיגנל:

השיטה מחייבת **דיוק גבוה בתזמון** של הסיגנל, לפי סטנדרט מוגדר (עבור WS2812B לדוגמה):

- '1' לוגי:
HIGH למשך ~800 ננו-שניות
LOW למשך ~450 נ"ש
- '0' לוגי:
HIGH למשך ~400 נ"ש
LOW למשך ~850 נ"ש

ה-ESP32 משמש כבקר חומרה עיקרי אשר שולט ברמזור ובפס הלדים באמצעות הפינים הייעודיים שתוארו קודם, ומבצע את ההפעלה בזמן אמת בהתאם להחלטות שמתקבלות מהסוכן המאומן. את ההוראות להפעלה הוא מקבל מהמחשב הראשי, Raspberry Pi 5, באמצעות **תקשורת UART** בעלת המאפיינים הבאים:

- **מהירות (Baudrate): כ - 9600** ביט לשנייה
- **מבנה בסיסי של כל מסגרת UART:**
 - 1 סיבית התחלה (Start Bit)
 - 8 סיביות נתונים (Data Bits)
 - ללא סיבית זוגיות (No Parity)
 - 1 סיבית עצירה (Stop Bit)
- **ערוץ:** UART2 של ה-ESP32 ו-ttyAMA0 של ה-RPi
- **הקצאת פינים:**
 - RPI TX - GPIO 14 → ESP RX - GPIO 16
 - RPI RX - GPIO 15 ← ESP TX - GPIO 17
 - GND משותף בין ה-RPi ל-ESP32 נדרש לסינכרון רמות מתחים.

במערכת מוגדרים שני סוגים שונים של הודעות אשר מגיעות מה-RPi:

1. הודעות בקרה לפס הלדים

פורמט: #23bit.23bit.23bit.23bit

- מייצגות את מצב התנועה עבור ארבעת הכיוונים (צפון, דרום, מזרח, מערב).
- כל קטע של 23 ביט מייצג את מצב הלדים לכיוון מסוים (למשל אילו כלי רכב נוכחים או נעים בו).
- במקרה בו אורך הכביש גדול משמעותית מכמות הלדים המייצגים אותו בסימולציה הפורמט ישתנה לשליחה של מספרים רגילים ולא ביטים, על מנת לייצג את מספר המכוניות הנמצאות על כל לד. במצב זה הסימולציה תציג צבעים שונים עבור מספרים שונים של מכוניות בכל לד.

2. הודעות בקרה לרמזור

○ פורמט: `#int`

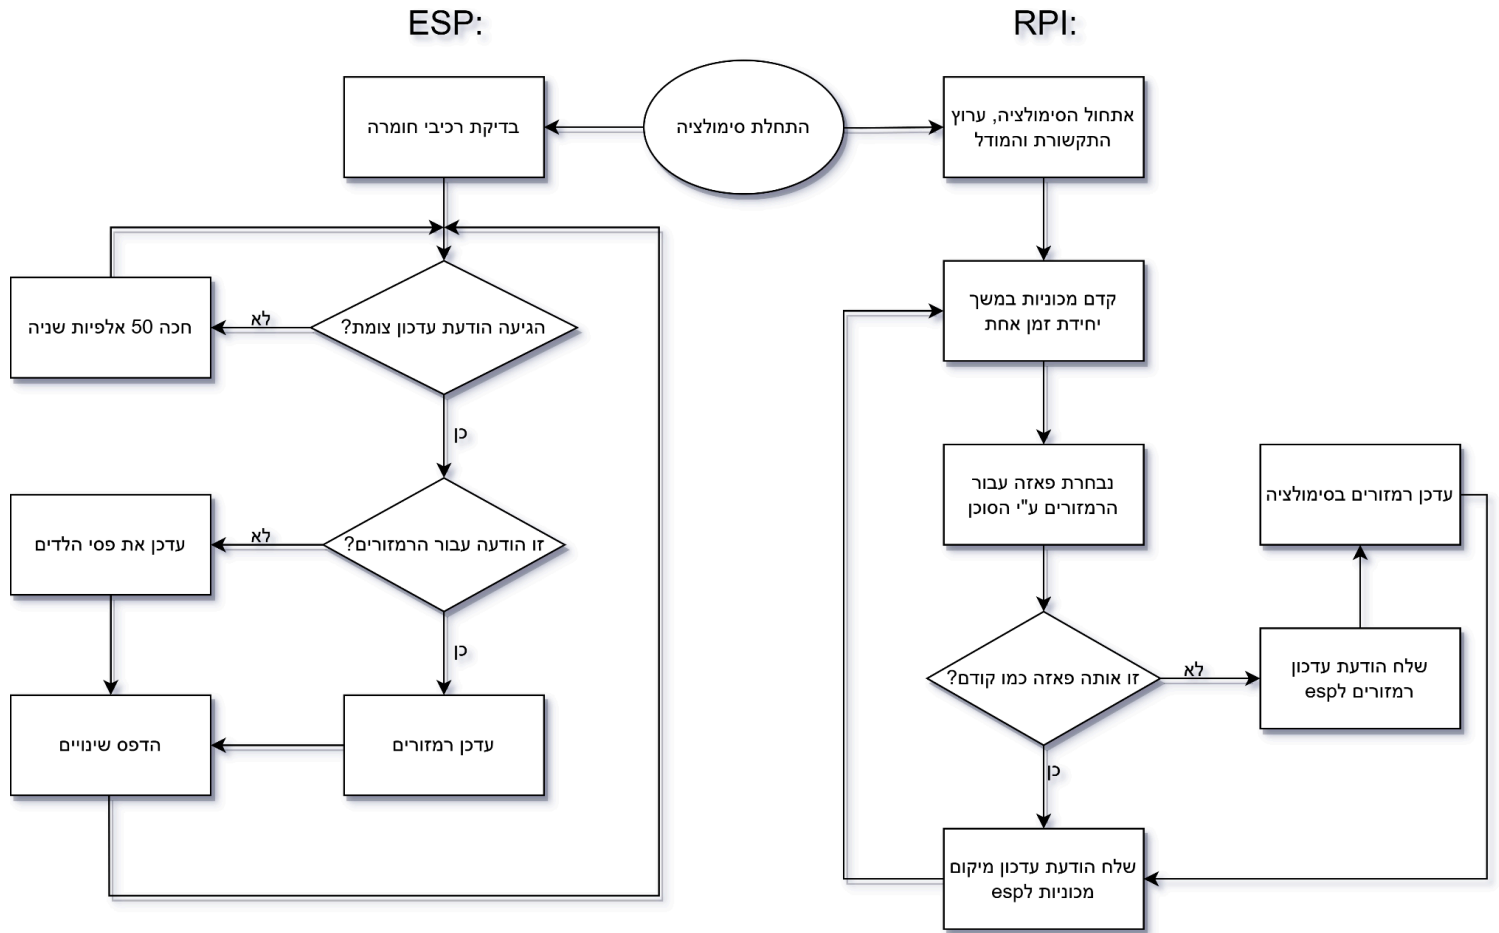
המספר מציין את מזהה הפאזה ברמזור (0, 1 או 2), בהתאם לתוכנית הרמזורים שנלמדה ע"י הסוכן.

במערכת זו, מחשב ה-**Raspberry Pi 5** מריץ את הסימולציה המלאה של הצומת וכן את הסוכן המאומן האחראי על קבלת ההחלטות בזמן אמת. לצורך יצירת אינטראקציה בין רכיבי התוכנה (הסימולציה והסוכן) לבין רכיבי החומרה הפיזיים (רמזורים ופסי לד), נוספה לסימולציה מחלקת Python בשם **Communication**, אשר אחראית על עיבוד המידע, תרגומו לפורמט קומפקטי, ושליחתו לבקר ה-**ESP32** בתקשורת UART.

מחלקת **Communication** מתעדכנת בזמן אמת מתוך אובייקטים קיימים בסימולציה: רשימות כלי הרכב בכל כביש, מצב הרמזורים, ומספר הפאזה הנוכחית. לאחר עיבוד הנתונים, היא דואגת לשלוח ל-ESP32 את המידע בפורמט אחיד, מה שמאפשר לסוכן לשלוט בפועל על רכיבי החומרה. ה-**ESP32** משמש כממשק בקרה פיזי, ללא צורך במעבדות יקרות או גישה לצומת אמיתית — וכך ניתן להציג את ביצועי הסוכן המאומן על מודל מוחשי.

את כל הקוד של הפרוייקט ניתן למצוא בגיטהאב: <https://github.com/iftachshalev/DJS>
כאשר על branch master קיימת הגרסה הפועלת והבדוקה העדכנית ביותר, על branch development קיימת הגרסה הניסיונית החדשה ביותר ועל branch esp32 קיים הקוד עבור esp השולט על רכיבי החומרה.

3.2 תרשימי זרימה של התוכנה



תמונה 7: תרשים פעולת המערכת

התרשים (תמונה 7) מתאר את מנגנון הפעולה והתקשורת בין רכיב ה-ESP32 (בקר המפעיל את הסימולציה הפיזית) לבין ה-Raspberry Pi (המחשב המריץ את האלגוריתם ומקבל החלטות בזמן אמת). עם התחלת הסימולציה, ה-Raspberry Pi מחשב את מצב הרמזורים לפי אלגוריתם למידת החיזוקים, שולח עדכון ל-ESP32, וזה מעדכן בהתאם את הלדים והרמזורים. התהליך חוזר על עצמו בכל יחידת זמן, תוך שמירה על זרימה סינכרונית והתאמה דינמית לתנאי הסימולציה.

הדיאגרמה מציגה:

- את רצף הפעולות שכל אחד מהרכיבים מבצע.
- מנגנון ההמתנה והאימות לפני ביצוע שינוי.
- ההפרדה בין לוגיקת קבלת ההחלטות (ב-Raspberry Pi) לבין שליטת החומרה (ב-ESP32).

3.3 תיאור מפורט של מרכיבי החומרה במערכת

המערכת שלנו כוללת מספר רכיבי חומרה מרכזיים שמאפשרים את תפעול הצומת ואת הדמייתו. להלן פירוט של כל רכיב, מאפייניו והסבר על התאמתו לדרישות המערכת:

1. מצלמת זיהוי עצמים

- **דגם:** מצלמת USB (כמו Logitech C920)

- **מאפיינים:**

- רזולוציה: 1080p
- קצב פריימים: 30 fps
- חיבור: USB 2.0/3.0

- **הסבר:**

- המצלמה מאפשרת צפייה בזמן אמת בצומת. היא מספקת נתונים ברזולוציה גבוהה מספיק לזיהוי עצמים כמו כלי רכב והולכי רגל (כמובן שבסימולציה הפיזית לא יהיה שימוש במצלמה שכן אין מכוניות לצלם).

2. מחשב Raspberry Pi

- **דגם:** Raspberry Pi 5

- **מאפיינים:**

- מעבד: Quad-core Cortex-A76 (ARM v8) 64-bit SoC @ 1.5GHz
- זיכרון RAM: 4GB
- חיבורים: USB 3.0, GPIO, HDMI, Ethernet, UART

- **הסבר:**

- ה-RPi מריץ את הסוכן המאומן ומבצע עיבוד של נתוני המצלמה. יכולת החיבור שלו למגוון התקנים הופכת אותו למתאים במיוחד לניהול המערכת.


3. ESP32

- **מאפיינים:**

- מעבד: Xtensa Dual-Core 32-bit LX6
- חיבורים: UART, GPIO, Wi-Fi, Bluetooth
- מתח הפעלה: 3.3V

- **הסבר:**


- ה-ESP32 מתפקד כיחידת בקרה אלקטרונית המתחברת ל-RPI באמצעות UART (תמונה 8). הוא שולט ברצועות LED (המייצגות מכוניות) ובנוריות LED (המייצגות רמזורים), כדי להדגים את פעולת הצומת בצורה פיזית.



תמונה 8: אופן חיבור ה-esp ל-RPI באמצעות תקשורת UART

4. רצועות LED המייצגות מכוניות (תמונה 9)

- **דגם:** WS2812B
- **מאפיינים:**
 - מספר לדים: 23
 - צבע: RGB, ניתן לשליטה על כל לד בנפרד
 - מתח הפעלה: 5V
- **הסבר:**
 - רצועות ה-LED משמשות להדמיית כלי הרכב בצומת. ניתן לשנות את צבעם ואת התדירות שלהם בהתאם לזרימת התנועה המדומה.



תמונה 9: אופן הפעלת פס הלדים על ידי מקור מתח חיצוני

5. נוריות LED (ייצוג רמזורים)

• מאפיינים:

- סוג: נוריות 5mm LED
- צבעים: אדום, צהוב, ירוק
- מתח הפעלה: 3.3V

• הסבר:

- נוריות אלו מדמות את הרמזורים בצומת. שינוי צבע הנוריות מתבצע לפי החלטות הסוכן ומבצע את ההדמיה של תפקוד הצומת בפועל.

6. מעגלי חישה והפעלה

- **מעגלי חישה:** כוללים את חיבור המצלמה ל-RPI ואת עיבוד התמונה לצורך זיהוי עצמים.
- **מעגלי הפעלה:** כוללים את חיבור ה-ESP32 לרצועות LED ולנוריות LED, וכן את השליטה עליהם באמצעות אותות דיגיטליים מה-RPI.

7. מקורות מתח

- **Raspberry Pi:** ספק מתח 5V 3A
- **ESP32:** מופעל באמצעות ה-RPI
- **רצועות LED ונוריות:** ספק מתח 5V חיצוני.
- **רמזורים:** מופעלים באמצעות ה-esp

3.4 בחינה והערכה של ביצועי המערכת

המערכת הורצה שלוש פעמים, בתנאים זהים מלבד בוחר הפעולה.

תנאים:

1. 50 מכוניות בכל סימולציה
2. 10,000 סימולציות
3. 50 מטר - אורך הדרך עד הצומת
4. צומת בסיסית דו כיוונית
5. 15 יחידות זמן - זמן מחזור קבוע(עבור בחרי פעולה: fc , lq)


בוחר הפעולה:

1. fc (fixed cycle) - מחליף את הרמזורים כל זמן קבוע.
2. lq (longest queue) - מחליף כל זמן קבוע ורק אם הרמזור של הכביש בעל התור הארוך ביותר אדום (מתאר רמזור עם עיבוד תמונה אך ללא בינה מלאכותית).
3. $qllearning$ - הסוכן המאומן, פועל לפי המדיניות שפיתח בשלב האימון, השמורה בטבלת ה Q שלו.

תוצאות:

1. fc - זמן המתנה ממוצע: 3.42, אחוז תאונות: 0.11.
2. lq - זמן המתנה ממוצע: 3.25, אחוז תאונות: 0.10.
3. $qllearning$ - זמן המתנה ממוצע: 2.97, אחוז תאונות: 0.03.

שיעור תאונות	זמן המתנה ממוצע	אסטרטגיה
11%	3.42 שניות	fc
10%	3.25 שניות	lq
3%	2.97 שניות	$q learning$



תמונה 10: תוצאות הרצת המודלים

מהתוצאות (תמונה 10) עולה בבירור כי הסוכן שלמד באמצעות למידת חיזוקים (Q-learning) הצליח לנהל את התנועה בצורה היעילה והבטוחה ביותר מבין שלוש השיטות שנבדקו.

מסקנות עיקריות:

1. שיפור בזמן ההמתנה:

- הסוכן המאומן הפחית את זמן ההמתנה הממוצע ל-2.97 שניות, לעומת 3.42 שניות בשיטת הזמן הקבוע (fc) ו-3.25 שניות בשיטת התור הארוך (lq).
- זה מצביע על יכולת הסתגלות טובה יותר של הסוכן לתנאי תנועה משתנים, תוך קבלת החלטות חכמות שמונעות הצטברות מכוניות בצומת.

2. הפחתת שיעור התאונות:

- הסוכן המאומן הפחית את שיעור התאונות ל-3% בלבד, לעומת 11% ו-10% בשיטות fc ו-lq בהתאמה.
- המשמעות היא שהסוכן לא רק פועל ביעילות, אלא גם תורם לבטיחות התנועה, כנראה על ידי הפחתת מצבים של חפיפות וכניסה לא מתואמת של כלי רכב לצומת.

3. יתרון הבינה המלאכותית:

- בעוד ש-fc ו-lq מבוססות על כללים פשוטים וקשיחים, הסוכן המאומן מפעיל שיקול דעת דינמי שמתחשב במצב הצומת בכל רגע.

- הדבר ממחיש את היתרון שבשימוש בלמידת חיזוקים לצורך ניהול מערכות מורכבות כמו תנועה עירונית, בהן קיימים שינויים תכופים וחוסר ודאות.

4. הבדלים קטנים יכולים להיות משמעותיים:

- ההבדלים בזמן ההמתנה אולי נראים קטנים (חצי שנייה בממוצע), אך כאשר מדובר באלפי כלי רכב ביום, מדובר בחיסכון ניכר בזמן, דלק וזיהום אוויר.

השוואת התוצאות מצביעה על כך שפתרון מבוסס בינה מלאכותית, ובפרט למידת חיזוקים, עולה בביצועיו על פתרונות קלאסיים, גם במדדים של יעילות וגם בבטיחות. זו עדות חזקה לכך שמערכות תחבורה חכמות מבוססות AI עשויות להיות מרכיב מרכזי בעתיד התנועה העירונית.

4. סיכום

הפיתוח של מערכת צומת דינמית, המבוססת על סימולציה וסוכן לומד, היה עבורנו הרבה מעבר לאתגר טכנולוגי. זה היה תהליך למידה מעמיק, שדרש מאיתנו לא רק ידע תיאורטי, אלא גם הבנה מערכתית, גישה יצירתית, ויכולת פתרון בעיות מורכבות בסביבה משתנה.

מהר מאוד הבנו שההצלחה לא תימדד רק בתוצאה הסופית – אלא גם בדרך שבה נבחר להתמודד עם כל שלב בתהליך. נדרשנו לשלב בין תחומים מגוונים כמו תכנות, בינה מלאכותית, חקר ביצועים, ניתוח נתונים ולוגיקת תנועה. כל אחד מהשלבים האלה אילץ אותנו לצאת מאזור הנוחות, ללמוד תוך כדי תנועה, ולהפוך ידע מופשט לפתרון ממשי שמספק תוצאות מדידות.

העובדה שהצלחנו לבנות מערכת המסוגלת לשפר פרמטרים כמו זמני המתנה בצומת, זרימת כלי רכב והפחתת עומסים – ואף לצמצם את מספר התאונות המדומות – נתנה לנו אישור לכך שהשיטה שפיתחנו אכן אפקטיבית.

למדנו לעבוד כצוות – לחלוק אחריות, לשתף רעיונות, לנהל קונפליקטים ולשפר זה את עבודתו של זה. גילינו כמה כוח יש בעבודת צוות אמיתית, שמבוססת על אמון, פתיחות והקשבה הדדית. בתוך כך, כל אחד מאיתנו חיזק מיומנויות אישיות – כמו ניהול זמן, חשיבה אנליטית, קבלת החלטות והיכולת להציג תהליכים ותובנות בצורה ברורה.

מעבר להיבטים הטכניים והצוותיים, אחד המרכיבים המהותיים ביותר בפרויקט היה תחושת המשמעות. הידיעה שהתוצר שלנו מדמה פתרון שיכול, באופן תיאורטי, לתרום להפחתת עומסי תנועה, לצמצום זיהום אוויר ולשיפור בטיחות בדרכים – העניקה לעבודה עומק נוסף. זו לא הייתה רק משימה לצורך למידה, אלא חוויה של יצירה שיש לה פוטנציאל להשפיע על העולם האמיתי.

בסופו של דבר, הפרויקט הזה שינה את האופן שבו אנחנו ניגשים לבעיות. הוא לימד אותנו שלמידה אמיתית מתרחשת כאשר אנחנו מתמודדים עם מצבים מורכבים, שואלים שאלות קשות, מתנסים, טועים, משפרים – וחוזרים שוב על כל התהליך. הוא גם הדגים לנו כמה רחוק אפשר להגיע כשמאחדים טכנולוגיה, חשיבה מערכתית ורצון ליצור שינוי.

ברצוננו להודות למנחינו – אורן למדן, יאיר קלינשטרן ואייל רזנבלט – על הליווי המקצועי, התמיכה, ההכוונה והייעוץ המסור לאורך כל שלבי הפרויקט. תרומתכם הייתה משמעותית להצלחתנו, ואנו מוקירים את הסבלנות, הזמינות והאמון שהענקתם לנו לאורך הדרך.

יפתח:

במהלך העבודה על הפרויקט, עברתי מסע משמעותי של למידה, חקירה והתפתחות אישית. מראשית הדרך, היה לי ברור שזה לא יהיה עוד פרויקט "סטנדרטי" – מדובר בשילוב בין תחומים מתקדמים במדעי המחשב, כמו למידת חיזוקים עמוקה, לבין עבודה מעשית שמחייבת בנייה, אינטגרציה בין מערכות, וחיבור בין תוכנה לחומרה. אך רק כשהתחלתי להיכנס לעומק העשייה, הבנתי את גודל האתגר – ואת גודל ההזדמנות שטמונה בו.

אחת החוויות הבולטות מבחינתי הייתה ההבנה עד כמה העולם של בינה מלאכותית רחב, דינמי, ובעיקר – לא מובן מאליו. לא מדובר רק באלגוריתמים מתמטיים או קוד שמריצים, אלא באינטראקציה עם סביבה מורכבת, בה יש לאמן סוכן ללמוד מדיניות התנהגות שמתאימה להקשר. התהליך של אימון הסוכן, קריאת מאמרים, בניית פונקציית התגמול, חקירת טבלאות Q ולבסוף יישום של כל זה במערכת גדולה יותר דרש ממני לשלב בין הבנה תאורטית עמוקה לבין יישום קונקרטי, מדויק ולא פעם – מתסכל.

בנוסף להעמקה בתחום הבינה המלאכותית, עבדתי לראשונה גם עם חומרה ואלקטרוניקה, תוך שימוש ברכיבים כמו ESP32, פסי לד ורמזורים פיזיים. תהליך זה דרש ממני ללמוד כיצד לחבר בין תוכנה לחומרה, כולל העברת מידע בין המחשב לבקר, טיפול בפרוטוקולי תקשורת ותיאום מדויק בין רכיבים שונים. נתקלתי באתגרים טכניים שונים כמו תקלות בקוד או בעיות סנכרון, אך בעבודה שיטתית הצלחתי לפתור אותם ולהביא את המערכת לתפקוד תקין, כך שכל הרכיבים עבדו יחד באופן מתואם.

היו רגעים לא פשוטים: באגים שנמשכו שעות, מודלים שלא התכנסו, חיבורים שלא עבדו, תקשורת שהתנתקה – אבל בכל פעם כזו למדתי משהו. למדתי להתמיד, לא לוותר, לפרק בעיה לחלקים, לבדוק שיטה אחר שיטה. עם הזמן, גם הבנתי עד כמה התהליך הזה מחזק בי לא רק את היכולות הטכניות, אלא גם את הביטחון העצמי, את תחושת המסוגלות ואת האמונה שלי בעצמי וביכולות שלי כמהנדס וכחוקר לעתיד.

מעבר להיבטים הטכנולוגיים, הפרויקט הזה גרם לי לחשוב גם על המשמעות הרחבה יותר של העשייה שלי. העבודה על מערכת רמזורים חכמה אינה רק אתגר טכני – היא מייצגת פוטנציאל לשיפור אמיתי באיכות החיים של אנשים: פחות תאונות, פחות זיהום אוויר, פחות תסכול בכבישים. המחשבה שהידע שרכשתי יכול, בתיאוריה, לשפר את המרחב העירוני בו כולנו חיים – העניקה לתהליך כולו ממד מוסרי, חברתי ומשמעותי יותר.

לסיכום, אני מרגיש שדרך הפרויקט הזה למדתי בעיקר על עצמי: על היכולות שלי, על הדרך שבה אני ניגש לבעיות, על הרצון שלי להעמיק, לשאול, לחקור – ובעיקר, על השאיפה שלי להמשיך ולתרום לעולם דרך טכנולוגיה. הפרויקט הזה היה עבורי יותר מעבודה – הוא היה חוויה מעצבת, והוכחה לכך שכאשר אני בוחר להתמודד עם אתגר גדול – אני יכול לצמוח ממנו באמת.

אלון:

במהלך פרויקט זה למדתי מספר דברים חדשים והעמקתי את הידע שלי בנושא למידת חיזוקים עמוקה, ובעיקר במובן המוחשי של הפרויקט – בניית המודל הפיזי, בו למדתי להתעסק עם רכיבים חדשים כמו פסי הלדים או הרמזורים, אשר לפני כן לא ידעתי עליהם כלום. בכך למדתי כיצד לחקור בצורה עצמאית, בין אם זה במהלך חקירת מאמרים לגבי הנושא או חקירת מפרטים של הרכיבים בהם השתמשנו.

בכל שלבי הפרויקט השונים – מתכנון הרעיון ועד בניית המודל הסופי – נדרשתי להתמודד עם אתגרים טכניים ומושגים מורכבים (כמו Deep Q-Learning ועוד...). התמודדות עם אתגרים אלו חיזקה בי תחושת מסוגלות, העמיקה את הידע שלי בתחום הבינה המלאכותית, ולימדה אותי רבות על סבלנות, התמדה ופתרון בעיות בזמן אמת.

מעבר להישגים הטכניים, התהליך כולו גרם לי להבין את המשמעות שהטמעת טכנולוגיות מבוססות בינה מלאכותית יכולה לגרום לשינויים ממשיים ומשמעותיים בחיי היום-יום של אנשים, וגרם לי להתעניין בתחום ההנדסה אף יותר.

5. ביבליוגרפיה

- Wei, H., Zheng, G., Yao, H., & Li, Z. (2018). *IntelliLight: A Reinforcement Learning Approach for Intelligent Traffic Light Control*, 2496–2505. <https://doi.org/10.1145/3219819.3220096>
- *Deep Reinforcement Learning for Traffic Signal Control: a review*. (n.d.). IEEE.org. <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=9241006>
- Liang, X., Du, X., Wang, G., & Han, Z. (2019b). A deep reinforcement learning network for traffic light cycle control. *IEEE Transactions on Vehicular Technology*, 68(2), 1243–1253.